Actividad 6
EVALUACIÓN Y VALIDACIÓN DE MODELOS

Clasificación de sentimientos en comentarios sobre aerolíneas

Materia:	*Gestión de Proyectos de Inteligencia Artificial*
Actividad:	*Actividad 6*
Alumno(a):	*Paola Quinto Martínez*
Matrícula:	*03039650*
Docente:	*Luis Ariel Vázquez Piña*
Fecha de entrega:	*25 Octubre 2026*

Declaración de Uso de Inteligencia Artificial

El alumno debe indicar de manera honesta si utilizó herramientas de Inteligencia Artificial (IA) para el desarrollo de esta actividad. Completa la siguiente tabla:

Herramienta de IA utilizada	¿La usaste?	Propósito / Descripción de uso
ChatGPT / OpenAI	☒ Sí ☐ No	Apoyo para organizar, revisar y mejorarla redacción del reporte, explicar la metodología y estructurar el análisis.
Claude (Anthropic)	☒ Sí ☐ No	Revisión de la tarea: sugerencias para mejorar la redacción, el objetivo SMART y las explicaciones, usando un lenguaje sencillo.
Gemini (Google)	☐ Sí ☒ No	No utilizada.
Copilot (Microsoft)	☐ Sí ☒ No	No utilizada.
Otra (especifica):	☒ Sí ☐ No	Codex: apoyo para implementar, revisar y ejecutar código y pruebas.

Actividad 6

1. Introducción

La clasificación automática de sentimientos permite organizar opiniones expresadas en texto y puede apoyar la priorización de comentarios que requieren revisión. En este trabajo se evalúan modelos para clasificar comentarios sobre aerolíneas en tres categorías: negativa, neutral y positiva. Se utiliza el conjunto Twitter US Airline Sentiment y se comparan un modelo base, Regresión Logística y Random Forest. La evaluación incorpora métricas globales y por clase, matrices de confusión, validación cruzada, curvas ROC/AUC, ajuste de umbral y comparación estadística. También se desarrolla una simulación académica de prueba A/B con datos sintéticos para ilustrar la comparación de dos procesos. La actividad no representa un sistema desplegado en producción ni demuestra beneficios operativos reales.

1.1 Objetivo SMART

Elegir (con semilla aleatoria 42) un modelo que clasifique comentarios sobre aerolíneas como negativos, neutrales o positivos, y que cumpla tres metas medibles: (1) F1 macro de al menos 0.70 en el conjunto de prueba, superando al modelo base por al menos 0.40; (2) variación menor a 0.02 entre las cinco particiones de validación cruzada; y (3) recall de al menos 0.90 para detectar comentarios negativos, ajustando el umbral de decisión.

Cada parte del objetivo es SMART: es específico (clasificar sentimientos de aerolíneas), medible (F1 macro, desviación estándar y recall), alcanzable (modelos estándar con un conjunto de datos público), relevante (ayuda a detectar quejas para atenderlas primero) y tiene fecha límite (25 de octubre de 2026). Además, se realiza una simulación A/B con datos sintéticos. El alcance se limita al conjunto de datos académico, sin afirmar despliegue ni eficacia operativa.

Resultado frente al objetivo: la Regresión Logística obtuvo F1 macro de 0.751 (unos 0.49 puntos por encima del modelo base), desviación estándar de 0.008 en validación cruzada y recall de 0.933 para comentarios negativos con umbral 0.30. Las tres metas se cumplieron.

2. Contexto y planteamiento del problema

Cuando existe un volumen elevado de comentarios, la revisión manual puede dificultar la identificación oportuna de opiniones negativas. Un clasificador de sentimientos podría ayudar a priorizar los comentarios para su revisión, pero una evaluación basada únicamente en exactitud puede ocultar un desempeño desigual entre categorías. Por ello, el problema se aborda como clasificación supervisada multiclase y se complementa con un análisis binario específico para detectar comentarios negativos.

3. Datos y preparación

El dataset Twitter US Airline Sentiment contiene originalmente 14,640 registros y 15 columnas. Se utiliza `text` como variable predictora y `airline_sentiment` como etiqueta. La distribución inicial es de 9,178 comentarios negativos (62.69 %), 3,099 neutrales (21.17 %) y 2,363 positivos (16.14 %). Debido al desbalance de clases, se prioriza F1 macro, que asigna el mismo peso a cada clase.

El diagnóstico identificó 25 textos con etiquetas contradictorias, representados en 57 filas. En la preparación se documentó la exclusión de esos textos del modelado y la eliminación de duplicados exactos, con el propósito de evitar objetivos incompatibles para un mismo texto. Esta decisión reduce el volumen de datos y puede modificar la distribución de clases.

Etapa de preparación	Cantidad reportada
Registros originales	14,640
Registros después de depuración	14,402
Textos con etiquetas contradictorias	25 textos / 57 filas
Solapamiento de textos entre entrenamiento y prueba	0

Las cantidades finales deben interpretarse junto con el registro de ejecución del notebook, ya que dependen de las reglas de limpieza aplicadas. Los datos corresponden a comentarios históricos sobre aerolíneas y no necesariamente representan otros sectores, idiomas o periodos.

4. Metodología y modelos evaluados

Se empleó una división agrupada por texto mediante StratifiedGroupKFold, con cinco particiones y semilla 42. En la ejecución reportada se utilizaron 11,521 registros para entrenamiento y 2,881 para prueba, sin textos compartidos entre ambos conjuntos. La validación cruzada se realizó sobre entrenamiento con cinco particiones agrupadas. TF-IDF se incorporó dentro de cada pipeline para que la representación se ajuste con los datos de entrenamiento de cada partición.

Se compararon DummyClassifier con estrategia de clase mayoritaria como línea base, Regresión Logística y Random Forest. La métrica principal fue F1 macro, acompañada por exactitud, precisión macro, recall macro y F1 ponderado. El conjunto de prueba se utilizó para describir el rendimiento final, mientras que la validación cruzada permitió estimar la estabilidad.

4.1 Registro de experimentos

Para que los resultados se puedan repetir, la siguiente tabla resume la configuración usada y dónde queda la evidencia en el notebook y en la carpeta de resultados.

Elemento	Configuración
Datos	Twitter US Airline Sentiment; 14,402 registros después de la limpieza
Semilla aleatoria	42 (en todas las particiones y modelos)
Partición	Entrenamiento 11,521 y prueba 2,881, agrupadas por texto (sin textos repetidos entre ambos)
Texto a números (TF-IDF)	Palabras sueltas y pares de palabras; mínimo 2 apariciones; hasta 40,000 términos (30,000 en Random Forest)
Modelo base	DummyClassifier: siempre predice la clase más frecuente (negativa)
Regresión Logística	C = 2.0; clases balanceadas; máximo 1,000 iteraciones
Random Forest	120 árboles; profundidad máxima 45; mínimo 2 muestras por hoja; clases balanceadas
Validación cruzada	5 particiones agrupadas por texto, solo con datos de entrenamiento
Evidencia guardada	Carpeta resultados/: metricas_modelos.csv, validacion_cruzada.csv, analisis_umbral.csv, resumen.json y gráficas

5. Resultados de clasificación

Modelo	Exactitud	Precisión macro	Recall macro	F1 macro	F1 ponderado
Regresión Logística	0.803	0.746	0.757	0.751	0.805
Random Forest	0.758	0.694	0.714	0.702	0.764
DummyClassifier	0.630	0.210	0.333	0.258	0.487

Regresión Logística obtuvo el mayor F1 macro en el conjunto de prueba (0.751), seguida de Random Forest (0.702) y DummyClassifier (0.258). Esto indica que Regresión Logística fue la alternativa con mejor equilibrio de desempeño entre las tres clases en esta ejecución. La exactitud del modelo base resulta menos informativa por sí sola, dado que la clase negativa representa la mayoría de los registros.

Cómo leer estas métricas, en palabras sencillas: la exactitud es el porcentaje de comentarios clasificados correctamente; la precisión indica, de los comentarios que el modelo marca como de una clase, cuántos realmente lo son; el recall indica, de los que realmente son de esa clase, cuántos logró encontrar; y el F1 combina precisión y recall en un solo número. Como aquí lo más importante es no perder quejas (clase negativa) y la clase negativa es muy grande, se usa F1 macro (promedio de las tres clases) como métrica principal y el recall para la clase negativa.

5.1 Resultados por clase

Modelo y clase	Precisión	Recall	F1	Soporte
Regresión Logística — negativa	0.893	0.864	0.878	1,816
Regresión Logística — neutral	0.615	0.670	0.642	610

Modelo y clase	Precisión	Recall	F1	Soporte
Regresión Logística — positiva	0.730	0.736	0.733	455
Random Forest — negativa	0.878	0.814	0.845	1,816
Random Forest — neutral	0.546	0.656	0.596	610
Random Forest — positiva	0.658	0.673	0.665	455

Regresión Logística mostró el mejor F1 en las tres clases. La categoría neutral fue la más difícil de clasificar, con F1 de 0.642, mientras que el F1 de la clase negativa fue 0.878. Esta diferencia sugiere que las expresiones neutrales pueden compartir características lingüísticas con opiniones positivas o negativas.

5.2 Matrices de confusión

Las matrices de confusión permiten identificar los tipos de errores cometidos por cada modelo. En Regresión Logística se clasificaron correctamente 1,569 comentarios negativos, 409 neutrales y 335 positivos. En Random Forest se clasificaron correctamente 1,478 negativos, 400 neutrales y 306 positivos. Estos resultados muestran una ventaja de Regresión Logística en el conjunto evaluado.

Real \ Predicción	Negativa	Neutral	Positiva
Negativa	1,569	189	58
Neutral	135	409	66
Positiva	53	67	335

Interpretación: los errores más frecuentes son 189 comentarios negativos clasificados como neutrales y 135 neutrales clasificados como negativos, es decir, la clase neutral se confunde con las otras dos. En cambio, casi no se confunden negativos con positivos (58 y 53 casos). Para el objetivo de detectar quejas, el error más costoso es el de los 247 comentarios negativos que el modelo no reconoció como negativos (189 + 58), lo que corresponde a un recall de 0.864 para esa clase.

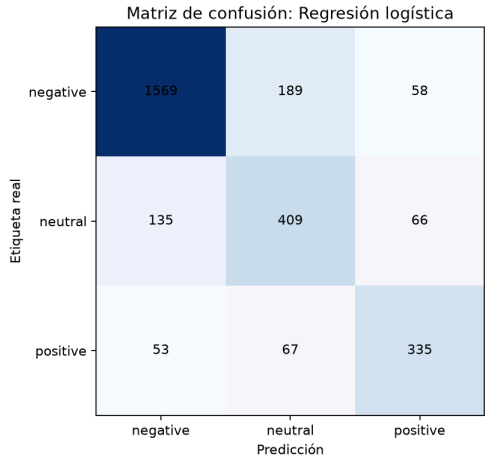


Figura 1. Matriz de confusión de Regresión Logística.

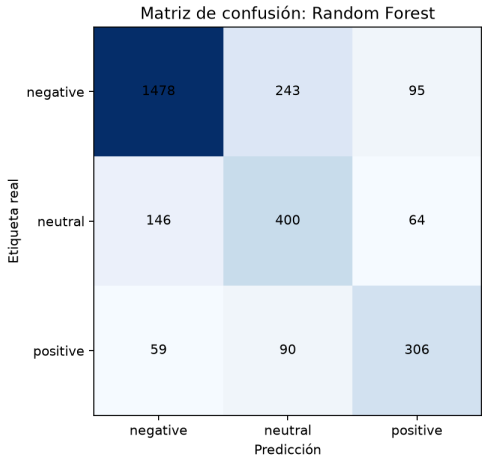


Figura 2. Matriz de confusión de Random Forest.

6. Validación cruzada

Modelo	F1 macro medio	Desv. estándar	F1 mínimo	F1 máximo	Exactitud media
DummyClassifier	0.258	0.000	0.258	0.258	0.630
Regresión Logística	0.744	0.008	0.733	0.753	0.797
Random Forest	0.698	0.013	0.678	0.709	0.753

Regresión Logística alcanzó un F1 macro medio de 0.744 y una desviación estándar de 0.008. Random Forest obtuvo un F1 macro medio de 0.698 y una desviación estándar de 0.013. En las particiones evaluadas se mantuvo el orden de desempeño, con menor variabilidad para Regresión Logística. Esta estabilidad es relativa al esquema de validación y no garantiza el mismo rendimiento ante datos nuevos de otro periodo.

Comparación con el modelo base: el DummyClassifier siempre responde "negativo". Por eso acierta el 63 % de las veces, pero su F1 macro es solo 0.258 porque nunca detecta comentarios neutrales ni positivos. La Regresión Logística lo supera por unos 0.49 puntos de F1 macro, tanto en validación cruzada (0.744) como en la prueba (0.751), así que el modelo sí aprende algo útil más allá de la clase mayoritaria.

7. Curvas ROC y AUC

El AUC macro One-vs-Rest reportado para Regresión Logística fue 0.918 y para Random Forest 0.882. Estas cifras indican que Regresión Logística mostró mayor capacidad de discriminación en la evaluación realizada. Las curvas ROC ilustran el intercambio entre la tasa de verdaderos positivos y la tasa de falsos positivos al variar el umbral. AUC no sustituye las métricas por clase ni permite determinar por sí solo el umbral más conveniente.

AUC por clase, tomado de la Figura 3: Regresión Logística, negativa 0.930, neutral 0.879 y positiva 0.944; Random Forest, negativa 0.889, neutral 0.846 y positiva 0.911. La clase neutral vuelve a ser la más difícil, igual que en el F1 por clase.

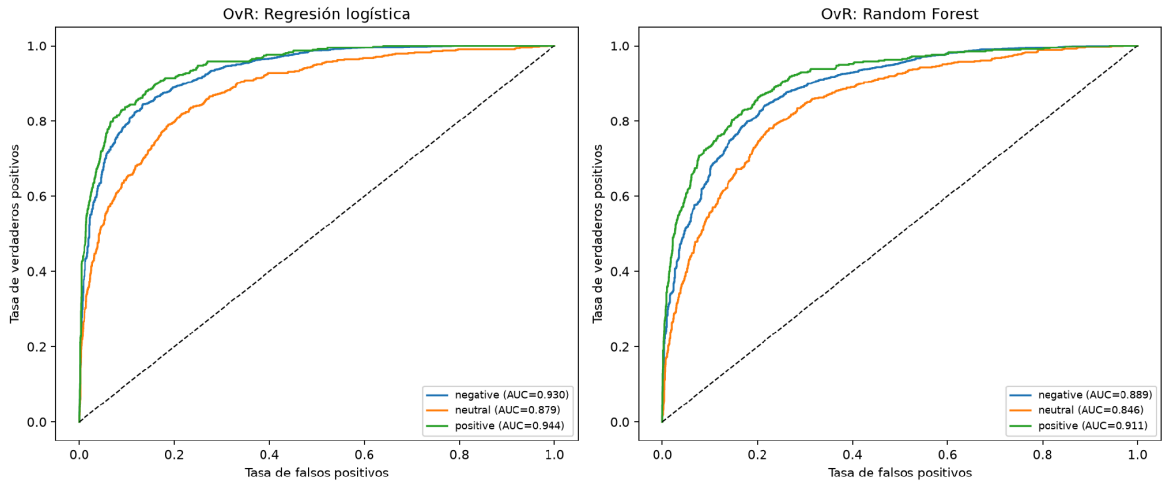


Figura 3. Curvas ROC One-vs-Rest de Regresión Logística y Random Forest.

8. Ajuste del umbral para detectar comentarios negativos

Se evaluaron umbrales de 0.30, 0.40, 0.50, 0.60 y 0.70 para convertir la probabilidad estimada de la clase negativa en una alerta binaria. La selección de un umbral debe realizarse con datos de validación y mantenerse fijo para la evaluación final; no debe optimizarse directamente sobre el conjunto de prueba.

Umbral	Precisión	Recall	F1	Falsos positivos	Falsos negativos
0.30	0.851	0.933	0.890	296	121
0.40	0.885	0.888	0.886	209	204
0.50	0.919	0.828	0.871	132	313
0.60	0.944	0.747	0.834	80	460
0.70	0.960	0.642	0.769	49	651

El umbral 0.30 presentó el mayor recall (0.933), lo que reduce los comentarios negativos no detectados, pero produjo 296 falsos positivos. En contraste, el umbral 0.70 alcanzó una precisión de 0.960, aunque dejó 651 comentarios negativos sin detectar. La elección debe considerar el costo relativo de omitir una queja y la capacidad del equipo para revisar alertas.

Cómo se eligió el 0.30, la elección se hizo con datos de validación (predicciones del entrenamiento hechas sin ver cada comentario), donde 0.30 tuvo el mejor F1 (0.881). La tabla anterior, calculada en el conjunto de prueba, solo informa el resultado final. Como 0.30 es el valor más bajo que se probó, un umbral menor podría detectar aún más quejas; probar valores desde 0.10 queda como mejora futura.

Justificación según el impacto: si perder una queja cuesta c veces lo que cuesta revisar una falsa alarma, el costo total es c × falsos negativos + falsos positivos. Los valores de c son supuestos de ejemplo, no datos reales. Si c =

1, el umbral 0.40 es apenas mejor (413 contra 417); si c es 2 o más, el umbral 0.30 es el mejor. En atención a clientes, no atender una queja suele ser peor que revisar una alerta de más, por lo que se recomienda 0.30.

Umbral	Falsos negativos	Falsos positivos	Costo si c = 1	Costo si c = 2	Costo si c = 5
0.30	121	296	417	538	901
0.40	204	209	413	617	1,229
0.50	313	132	445	758	1,697
0.60	460	80	540	1,000	2,380
0.70	651	49	700	1,351	3,304

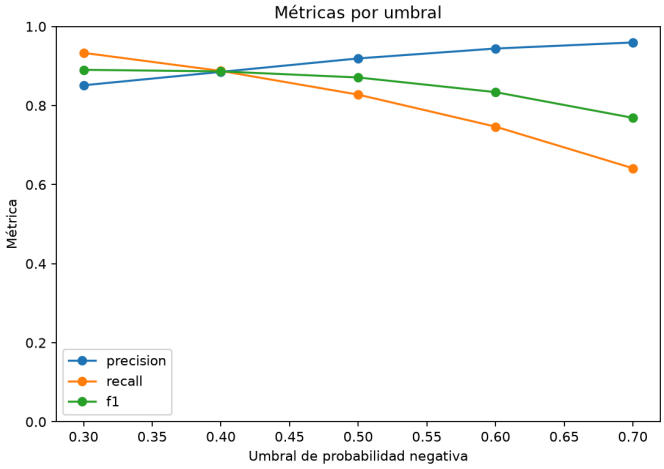


Figura 4. Variación de precisión, recall y F1 al cambiar el umbral de probabilidad negativa.

9. Comparación estadística entre modelos: McNemar

La prueba de McNemar compara los errores de dos modelos aplicados a las mismas observaciones. En la ejecución reportada, 284 casos fueron correctos únicamente para Regresión Logística y 155 únicamente para Random Forest. Se reportó un estadístico con corrección de continuidad de 37.321 y un valor p de 7.62×10^{-10}. Con un nivel de significancia de 0.05, existe evidencia de una diferencia entre los patrones de acierto y error de ambos modelos en ese conjunto. El valor p reportado es el de la versión exacta de la prueba; el estadístico 37.321 corresponde a la versión con corrección de continuidad, que daría un valor p cercano a 1.0×10^{-9}. Ambas versiones llevan a la misma conclusión.

Este resultado no demuestra un beneficio operativo ni equivale a una prueba A/B. McNemar compara predicciones emparejadas; una prueba A/B compara condiciones o procesos asignados a grupos independientes bajo un protocolo experimental.

10. Diseño y resultados de la simulación A/B

Como no se dispone de registros de una prueba operativa real, se realizó una simulación académica con datos sintéticos para ilustrar la comparación de dos procesos de detección de comentarios negativos. El grupo A representa el proceso de referencia y el grupo B representa un proceso asistido. Los resultados no corresponden a clientes reales ni demuestran una mejora operativa comprobada.

Se definieron como supuestos un recall de referencia de 0.65, un recall esperado del proceso asistido de 0.75, prevalencia de comentarios negativos de 0.30, significancia de 0.05, potencia objetivo del 80 % y semilla aleatoria 42. El cálculo de potencia registrado estimó 329 comentarios negativos reales por grupo. Con una prevalencia asumida del 30 %, se generaron 1,097 casos sintéticos para cada grupo.

Hipótesis de la prueba: la hipótesis nula es que el recall de A y B es igual; la alternativa es que son diferentes (prueba de dos colas). Los valores de 0.65 y 0.75 y la prevalencia de 30 % son supuestos del ejercicio; no provienen del modelo y la prevalencia real del conjunto de datos es mayor (63 %). En una prueba real, A sería el proceso sin el modelo y B el proceso apoyado por el modelo, con casos asignados al azar.

Indicador	Grupo A: control	Grupo B: asistido
Casos totales	1,097	1,097
Comentarios negativos reales	329	329
Negativos detectados	216	237
Recall	65.65 %	72.04 %
Alertas falsas	144	175
Precisión de alertas	60.00 %	57.52 %

La diferencia observada de recall entre B y A fue de 6.38 puntos porcentuales. La prueba de dos proporciones produjo un estadístico z de 1.768 y un valor p de 0.0771. El intervalo de confianza del 95 % para la diferencia fue de −0.68 a 13.44 puntos porcentuales. Como el valor p es mayor que 0.05 y el intervalo incluye cero, no se encontró evidencia estadística suficiente para concluir que el recall de B sea distinto al de A en esta simulación.

El grupo B detectó 21 comentarios negativos adicionales, pero generó 31 alertas falsas más y tuvo una precisión menor. La simulación ilustra que incrementar el recall puede aumentar la carga de revisión y que una diferencia observada no necesariamente es estadísticamente significativa.

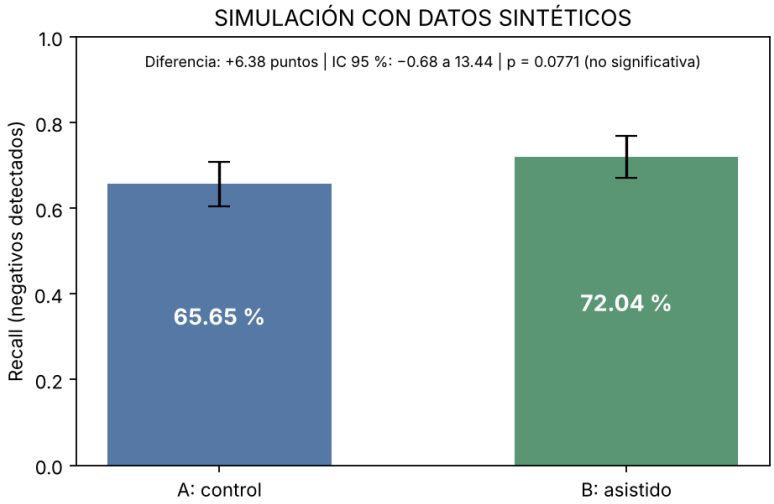


Figura 5. Comparación de recall en la simulación A/B con datos sintéticos.

Estos resultados describen exclusivamente una simulación sintética con parámetros definidos previamente. Para una prueba A/B real se necesitaría asignar casos de manera controlada, utilizar criterios consistentes de etiquetado, definir una métrica primaria antes de analizar los datos y reunir una muestra suficiente. La simulación demuestra el procedimiento estadístico, no la eficacia real del modelo.

10.1 Diferencia entre validación cruzada y prueba A/B

Son pruebas distintas que se complementan. La validación cruzada revisa si el modelo es confiable con datos históricos; la prueba A/B revisa si usarlo mejora un resultado en la práctica. Un modelo puede salir muy bien en validación cruzada y aun así no mejorar el proceso real, y por eso ambas se reportan por separado.

Aspecto	Validación cruzada	Prueba A/B
¿Qué pregunta responde?	¿El modelo funciona de forma estable con datos históricos?	¿Usar el proceso B cambia el resultado frente al proceso A?
¿Con qué datos?	Partes distintas del mismo conjunto de datos etiquetado	Casos nuevos repartidos al azar en dos grupos
¿Cuándo se hace?	Antes de usar el modelo (desarrollo)	Con el modelo en uso o en simulación (evaluación del efecto)
¿Qué compara?	Un modelo contra sí mismo en 5 particiones, y contra el modelo base	Dos grupos de casos (A y B)
Resultado en este trabajo	F1 macro de 0.744 con desviación 0.008: el modelo es estable	Recall 65.65 % contra 72.04 %, p = 0.0771: sin evidencia de diferencia

11. Impacto potencial de negocio

La carpeta de resultados incluye un escenario ilustrativo escalado a 1,000 comentarios. Según las métricas del holdout y el umbral de 0.30, se estiman aproximadamente 588 comentarios negativos detectados, 42 negativos no detectados y 103 alertas falsas. Estas cifras son proyecciones matemáticas basadas en la distribución y el desempeño del conjunto académico, no conteos operativos.

Para cuantificar un impacto financiero se requerirían datos del volumen real de comentarios, tiempo promedio de revisión, costo por revisión, costo asociado a una queja negativa no detectada y capacidad de atención del equipo. Sin esos datos no es posible afirmar ahorros ni calcular un ROI fiable.

Un recall alto significa que se pierden pocas quejas, y una precisión menor significa más alertas falsas que alguien debe revisar. Con el umbral 0.30, de cada 1,000 comentarios se generarían unas 691 alertas, de las cuales 588 serían quejas reales; a cambio, solo 42 quejas quedarían sin detectar. El equipo de atención debe decidir si puede revisar ese volumen de alertas.

12. Limitaciones y amenazas a la validez

- El conjunto contiene comentarios históricos sobre aerolíneas y puede no representar otros sectores, empresas o periodos.
- Se identificaron textos con etiquetas contradictorias; su tratamiento puede influir en el rendimiento y en la distribución de clases.
- La evaluación se basa en una partición de prueba y validación cruzada sobre entrenamiento; una validación temporal o externa sería útil.
- El umbral elegido implica un compromiso entre falsos positivos y falsos negativos.
- La simulación A/B usa datos sintéticos y no demuestra resultados operativos reales.
- No se dispone de costos ni tiempos reales para cuantificar beneficios financieros.

13. Conclusiones y recomendaciones

La evaluación comparativa identificó a Regresión Logística como el modelo con mejor desempeño en esta ejecución, con F1 macro de 0.751 en el conjunto de prueba y 0.744 de promedio en validación cruzada. Random Forest obtuvo F1 macro de 0.702 en prueba y 0.698 en validación cruzada, mientras que el modelo base alcanzó 0.258. La clase neutral continúa siendo el principal reto.

Meta SMART: las tres metas se cumplieron en esta ejecución (F1 macro de 0.751, desviación de 0.008 en validación cruzada y recall de 0.933 para comentarios negativos con umbral 0.30). Además, el modelo supera claramente al modelo base (0.258).

El análisis del umbral mostró que 0.30 favorece la detección de comentarios negativos, aunque genera más falsas alarmas. La prueba de McNemar indicó diferencias en los patrones de error de los dos modelos. Por separado, la simulación A/B mostró una diferencia de recall de 6.38 puntos porcentuales a favor de B, pero no estadísticamente significativa al nivel de 0.05. Estos hallazgos no permiten afirmar que el sistema genere beneficios reales en operación.

Es importante no confundir validación cruzada con prueba A/B: la primera muestra que el modelo es estable con datos históricos y la segunda mide el efecto de usarlo en un proceso. En este trabajo la segunda es solo una simulación sintética.

Referencias bibliográficas

- Universidad Tecmilenio. (s. f.). T13: Evaluación de modelo [PDF].
- Universidad Tecmilenio. (s. f.). T14: Validación de modelos [PDF].